



Attention



Seq2Seq

입력 데이터로 시퀀스(Sequence)를 받아 시퀀스를 생성하는 시퀀스 변환 모델

- 기계 번역
- QA
- 요약




Seq2Seq


입력을 처리하는 인코더와 출력을 처리하는 디코더로 구성

- 입출력 길이가 다른 것에 대처
- 역할 분리(NLU/NLG)
- 모델 설계 용이

Seq2Seq 구조



RNN seq2seq 모델 구조







RNN seq2seq의 한계

- Gradient Vanishing
->LSTM으로 극복 시도
- Long term dependency(Information Vanishing)


Attention의 컨셉




Attention의 컨셉




Attention의 컨셉



Attention의 컨셉



Attention의 컨셉





Attention의 컨셉

Context를 그냥 전달하는 것이 아니라 이전 문맥 정보에서 관련 있는 내용에 가중치를 부여해 context vector를 만들어냄

1. Q, K의 유사도를 계산(각 벡터별 유사도 점수)
2. Softmax로 가중치를 계산
3. 가중치를 반영한 새로운 context vector 합성



Attention의 컨셉

Query

Key

Value

Key

Value

Key

Value



Attention의 컨셉

결제를
취소했는데
환불은 언제
되나요?

배송, 지연

환불, 취소

제품 불량,
교환

문서 1

문서 2

문서 3



Attention의 컨셉

love

나는

Value

사과를

Value

좋아해


Value



Attention의 컨셉

love	0.1	나는	Value1
	0.2	사과를	Value2
	0.7	좋아해	Value3

Attention의 컨셉






Attention의 컨셉

$$e = W_s \cdot \tanh(W_{En}H + W_{De}s_{t-1})$$

$$\alpha = \text{softmax}(e)$$

$$a = \sum_{i=1}^T \alpha_i h_i = H \cdot \alpha$$

Attention의 컨셉



Attention의 컨셉

The diagram illustrates the Attention mechanism formula. It shows a purple 2x3 matrix labeled Q multiplied by an orange 3x2 matrix labeled K^T . The result is divided by $\sqrt{d_k}$ and passed through a softmax function. This is then multiplied by a blue 2x3 matrix labeled V to produce a pink 2x3 matrix labeled Z .

$$\text{softmax} \left(\frac{Q \times K^T}{\sqrt{d_k}} \right) V = Z$$