



LLM & RAG



LLM의 구조적 한계

- 확률적 언어 모델
- Knowledge Cutoff(Static Knowledge)
- 한정된 context window
- 의미 이해의 부재
- 추론 구조의 불명확성
- 낮은 해석 가능성



한계 1. 확률적 언어 모델

LLM은 다음 단어의 확률 분포를 예측

사실 판단(Factual Reasoning)보다는 언어적 일관성과
패턴 재현에 강점

극복 시도

**RAG, Tool-augmented LLM,
Neuro-symbolic Reasoning**



한계 2. Knowledge Cutoff

훈련 시점에서 고정된 데이터를 학습

실제 세계는 지속적으로 변화하는데 해당 데이터는 특정 시점에서 고정되어있음

극복 시도 **RAG, Continuous Learning**



한계 3. 한정된 Context Window

Transformer 구조는 입력 토큰 길이에 따라 한정된 context window 내에서만 정보를 유지

long-term context나 세션 간 기억은 기본 구조에서는
없음

극복 시도 **Advanced Attention,**
Agent Memory, Vector Memory



한계 4. 의미 이해의 부재

LLM은 언어의 의미(Semantics)를 이해하는 것이 아닌
형태(Syntax/statistics)를 학습

사람의 사고처럼 개개인의 세계관을 구성하고 이를
바탕으로 이해 및 출력하는 것이 아님

극복 시도 **Multimodality, Embodied AI, RLHF**



한계 5. 추론 구조의 불명확성

LLM에서의 추론 동작은 통계적 연관성에 기반한 과정이며
명시적인 논리 구조를 사용하는 것이 아님

극복 시도

CoT / Graph-of-Thought
Symbolic Reasoner



한계 6. 낮은 해석 가능성

상용 LLM의 파라미터는 수십B 단위로 모델의 결정 과정을 직접 검증하기 어려움

때문에 특정 답변을 생성한 이유를 해석할 가능성이 매우 낮음


극복 시도

Mechanistic Interpretability

Concept Bottleneck Model

Retrieval-Augmented Generation

1. 프롬프트 입력
2. 관련 문서 검색
3. 프롬프트 + 문서
4. 답변 생성





그 이외의 문제

너무 커진 LLM

상용 LLM의 최저 크기는 70B 수준

- 리소스
- Latency
- 비용




모델 경량화의 다양한 시도들

- Pruning
- Knowledge Distillation
- RoLA
- Quantization

Pruning

- 뉴런
- 레이어
- 개별 가중치





Knowledge Distillation

- Response-based Distillation


teacher 모델의 확률 분포 자체를 모방

- Data Distillation

teacher 모델이 생성한 합성 데이터로 모델 학습

Low-rank Approximation

가중치 행렬을 낮은
차원의 가중치 행렬의
근사로 표현



The diagram illustrates the Low-rank Approximation concept. It shows a large green rectangle labeled M with dimensions $m \times n$ below it. To its right is an approximation symbol $\approx$. Next is a tall blue rectangle labeled L_k with dimensions $m \times k$ below it. To the right of L_k is a multiplication symbol $\times$. Finally, there is a yellow rectangle labeled R_k^T with dimensions $k \times n$ below it. The rectangles are outlined in black.

$$M \approx L_k \times R_k^T$$

$m \times n$ $m \times k$ $k \times n$



Quantization

일반적으로 32비트 부동 소수점을 사용

이를 8비트 정수로 바꾸면 동일한 파라미터수를
유지하면서 $\frac{1}{4}$ 크기로 변환 가능